

CHƯƠNG 1: KHOA HỌC DỮ LIỆU

The Data Science Design Manual

Trần Văn Long

Trường Đại học Giao thông vận tải

Tháng 9, 2026

Ba Nhiệm Vụ Cốt Lõi Của Chương 1

Chương mở đầu đặt nền móng tư duy cho toàn bộ cuốn giáo trình với ba mục tiêu chính:

- **Tư duy Khoa học Dữ liệu:** Giải thích cách suy nghĩ của một nhà khoa học dữ liệu giỏi và phân biệt nó với các lập trình viên truyền thống.
- **Khai thác tiềm năng dữ liệu:** Học cách đặt ra các câu hỏi bao quát và sâu sắc hơn từ bất kỳ tập dữ liệu thô nào.
- **Thử thách thực tế:** Giới thiệu các dự án phân tích dữ liệu thực tế làm ví dụ trực quan xuyên suốt các chương tiếp theo.

Triết lý nền tảng

“Đầu vào rác, đầu ra rác” (Garbage In, Garbage Out). Khoa học dữ liệu thực thụ bắt đầu bằng việc “ngửi” dữ liệu thông qua các thử nghiệm khứu giác lành mạnh để sàng lọc rác trước khi áp dụng thuật toán.

Đối Chiếu Tư Duy: Khoa Học Máy Tính vs. Khoa Học Dữ Liệu

Sự khác biệt sâu sắc trong thế giới quan ảnh hưởng đến cách tiếp cận dữ liệu:

Khoa học Máy tính (Computer Science)	Khoa học Dữ liệu (Data Science)
Lấy phương pháp làm trung tâm: Say mê thuật toán, ngôn ngữ lập trình, hiệu năng điện toán.	Lấy dữ liệu làm trung tâm: Tập trung vào ý nghĩa thực tế của các con số hơn là công nghệ thô.
Thế giới ảo sạch sẽ: Muốn mọi thứ có tổ chức, đúng hoặc sai rõ ràng (logic nhị phân).	Thế giới thực hỗn độn: Sống chung với sai số, nhiễu và những sự biến động ngẫu nhiên.
Ám ảnh bởi giá trị số: Quan tâm đến độ dài phân thập phân (ví dụ: $8/13 = 0.61538461538$).	Quan tâm đến ý nghĩa thực tế: Chỉ sử dụng các chữ số có nghĩa cần thiết (ví dụ: $8/13 \approx 0.62$).

Chân Dung Một Nhà Khoa Học Dữ Liệu Giỏi

Thành công trong lĩnh vực dữ liệu đòi hỏi những phẩm chất tư duy đặc thù hơn là kỹ năng code thuần túy:

- **Sự tò mò bẩm sinh:** Luôn đặt câu hỏi “Tại sao?”, khao khát tìm hiểu cơ chế vận hành của thế giới xung quanh.
- **Kiến thức rộng và đa dạng:** Thường xuyên đọc tin tức, am hiểu một chút về mọi lĩnh vực để có thể trao đổi chuyên môn hiệu quả với các chuyên gia ngành khác.
- **Dũng cảm bước ra khỏi vùng an toàn:** Không ngại đối mặt với các lĩnh vực mới lạ, sẵn sàng tự học khi tiếp cận dữ liệu lạ.
- **Tư duy thực tế và hoài nghi lành mạnh:** Nhìn nhận những gì có thể làm từ tập dữ liệu hiện có thay vì than vãn về những thứ lý tưởng không thể có được.

Nghệ Thuật Đặt Câu Hỏi Từ Dữ Liệu

Nguyên tắc thực hành: Trước khi phân tích một tập dữ liệu mới, hãy tự đặt ra ít nhất **5 câu hỏi thú vị** mà tập dữ liệu đó có tiềm năng trả lời.

Ví dụ từ các nguồn dữ liệu thực tế:

- **Bóng chày (Baseball-Reference):** Người thuận tay trái có tuổi thọ ngắn hơn người thuận tay phải? (Phân tích dựa trên thông tin cá nhân của các kỳ thủ).
- **Dữ liệu phim ảnh (IMDb):** Những bộ phim nào thua lỗ nhiều nhất nhưng lại sở hữu dàn sao danh tiếng nhất?
- **Google Ngrams (Văn bản lịch sử):** Trực quan hóa sự trỗi dậy và suy tàn của các cụm từ (như “xử lý dữ liệu”) trong 200 năm qua để hiểu xu hướng văn hóa.
- **Dữ liệu Taxi New York:** Sử dụng thời gian di chuyển của taxi như một cảm biến đo lường chi tiết mức độ tắc nghẽn giao thông đô thị.

Thuộc Tính Của Dữ Liệu & Cảnh Báo Về “Dữ Liệu Lớn”

Hiểu rõ bản chất của dữ liệu là bước đầu tiên để làm sạch và xây dựng mô hình thành công:

- **Cấu trúc:** Dữ liệu có cấu trúc (dạng ma trận/bảng) so với dữ liệu không cấu trúc (như tweets, văn bản tự do). Bước đầu tiên luôn là chuyển dữ liệu không cấu trúc thành ma trận (ví dụ: mô hình túi từ - Bag of Words).
- **Tính chất số:** Dữ liệu định lượng (chiều cao, cân nặng - đưa trực tiếp vào công thức) so với dữ liệu định tính/phân loại (giới tính, màu tóc - cần mã hóa nhãn phù hợp).

Cảnh báo quan trọng: “Dữ liệu lớn thường là dữ liệu xấu”

Dữ liệu lớn (Big Data) hầu hết thu được thụ động dưới dạng sản phẩm phụ của hệ thống ghi nhật ký, do đó rất dễ bị thiên lệch lấy mẫu, chứa nhiều thư rác và trùng lặp. Tập dữ liệu **phù hợp nhất** luôn quan trọng hơn tập dữ liệu **lớn nhất**.

Hai Bài Toán Kinh Điển: Phân Loại & Hồi Quy

Hầu hết các thách thức trong khoa học dữ liệu đều quy về một hoặc cả hai dạng bài toán sau:

Bài toán Phân loại (Classification)

Định nghĩa: Gán một nhãn cho mục tiêu từ một tập hợp các khả năng riêng biệt (rời rạc).

Ví dụ điển hình:

- Dự đoán đội thắng cuộc trong trận đấu thể thao (Đội A hay Đội B?).
- Xác định thể loại của một bộ phim (Hài, chính kịch hay hoạt hình?).
- Phân loại thư rác (Spam hay Ham?).

Bài toán Hồi quy (Regression)

Định nghĩa: Dự báo giá trị của một đại lượng số cụ thể (hàm số liên tục) trong tương lai.

Ví dụ điển hình:

- Dự đoán cân nặng của trẻ sơ sinh dựa trên sức khỏe thai kỳ.
- Dự báo giá cổ phiếu hoặc giá dầu mỏ vào ngày mai.
- Dự đoán nhiệt độ hoặc lượng tuyết rơi năm nay.

Các Thách Thức Phân Tích Thực Tế (The Quant Shop)

Chương trình truyền hình thực tế *The Quant Shop* (2014) giới thiệu các dự án dự báo thú vị do sinh viên thực hiện, làm ví dụ minh họa xuyên suốt giáo trình:

- **Cân nặng trẻ sơ sinh (Hồi quy):** Dự đoán cân nặng của bé trước khi sinh để phát hiện sớm các rủi ro thai kỳ.
- **Mô hình hóa phim ảnh (Cả hai):** Dự đoán doanh thu phòng vé ngày Giáng sinh và dự đoán diễn viên đoạt giải Oscar.
- **Nghệ thuật đấu giá (Hồi quy):** Dự đoán giá bán của các bức tranh triệu đô từ danh
- **Dự báo bóng bầu dục (Phân loại):** Dự đoán nhà vô địch Super Bowl sử dụng thuật toán PageRank của Google trên đồ thị thi đấu.
- **Bảo hiểm người nổi tiếng (Hồi quy):** Áp dụng mô hình thống kê bảo hiểm nhân thọ để dự đoán tuổi thọ của người nổi tiếng.
- **Tham gia thị trường (Hồi quy):** Dự đoán biến động giá

Câu Chuyện Chiến Trường: “Đặt Câu Hỏi Đúng Trực Tiếp”

Dự án phân tích cảm xúc

Lydia/TextMap:

- Hệ thống thu thập văn bản quy mô lớn từ tin tức, blogs toàn cầu, định danh thực thể và phân tích cảm xúc (tích cực/tiêu cực) cho hơn 20 triệu thực thể.
- Đội ngũ bán hàng tự tin: *“Hệ thống của chúng tôi cực kỳ mạnh mẽ, nó có thể làm bất cứ điều gì!”*
- Khách hàng (như nhà sản xuất động cơ máy bay lớn) rất hào hứng nhưng không biết chính xác họ muốn biết điều gì từ mạng xã hội.

Bài học xương máu

Thế giới sẽ không tự nhiên tìm đến bạn chỉ vì bạn sở hữu một nguồn dữ liệu mới bóng bẩy.

Bạn phải biết cách đặt ra

những câu hỏi kinh doanh đúng đắn trước khi có thể biến dữ liệu thô thành giá trị và tiền bạc.

Tổng Kết Chương 1: Sự Khôn Ngoan Thắng Thế Thiên Tài

Làm thế nào để trở thành một nhà khoa học dữ liệu thực thụ?

- **Trí tuệ đến từ kinh nghiệm và sự khiêm tốn:** Thiên tài thể hiện ở sức mạnh kỹ thuật thuần túy, nhưng trí tuệ thể hiện ở việc biết lắng nghe dữ liệu, thừa nhận sai lầm trong quá khứ để tránh các cạm bẫy tương lai.
- **Giao thoa của ba thế giới:** Khoa học dữ liệu không phải là một nhánh của riêng CNTT; nó thành công nhờ sự kết hợp chặt chẽ giữa Kỹ thuật điện toán (CS), Toán học nghiêm ngặt (Thống kê) và sự thấu hiểu sâu sắc thực tế (Lĩnh vực ứng dụng).
- **Mục tiêu tối thượng:** Công việc của bạn không phải là chạy các mô hình phức tạp một cách mù quáng, mà là **biến những con số vô tri thành những hiểu biết sâu sắc có giá trị hành động**.