

CHƯƠNG 2: KIẾN THỨC TOÁN HỌC CƠ BẢN

The Data Science Design Manual

Trần Văn Long

Trường Đại học Giao thông vận tải

Tháng 9, 2026

1. Khác biệt cốt lõi: Xác suất và Thống kê

Lý thuyết Xác suất:

- Là nhánh toán học lý thuyết, suy diễn từ mô hình lý tưởng sang kết quả thực tế.
- **Dự đoán tương lai:** Xác định khả năng xảy ra của các sự kiện dựa trên các giả định hoàn hảo.
- Ví dụ: Giả định xúc xắc công bằng, tính xác suất ra mặt 6.

Thực nghiệm Thống kê:

- Là toán học ứng dụng, quy nạp từ quan sát thực tế để kiểm chứng/mô hình hóa thế giới.
- **Phân tích quá khứ:** Đặt câu hỏi hoài nghi về dữ liệu thô thu thập được để tìm quy luật ẩn.
- Ví dụ: Quan sát 1000 lần tung xúc xắc thực tế để kiểm tra xem nó có bị gian lận hay không.

2. Các khái niệm nền tảng về Xác suất

- **Không gian mẫu (S):** Tập hợp tất cả các kết quả có thể xảy ra của một thí nghiệm (ví dụ tung 2 xúc xắc có 36 kết quả).
- **Sự kiện (E):** Một tập con được chỉ định của không gian mẫu ($E \subseteq S$).
- **Biến ngẫu nhiên (V):** Một hàm số ánh xạ từ các kết quả trong không gian mẫu sang các giá trị số thực.
- **Giá trị kỳ vọng ($E(V)$):** Trung bình có trọng số xác suất của tất cả kết quả có thể xảy ra:

$$E(V) = \sum_{s \in S} p(s) \cdot V(s)$$

- **Tính độc lập:** Hai sự kiện A và B độc lập khi và chỉ khi:

$$P(A \cap B) = P(A) \times P(B)$$

3. Xác suất có điều kiện & Định lý Bayes

Định nghĩa Xác suất có điều kiện

Đo lường khả năng xảy ra của sự kiện A khi biết sự kiện B đã xảy ra:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Định lý Bayes – Trọng tâm cập nhật bằng chứng

Công cụ đảo ngược hướng của các mối quan hệ phụ thuộc xác suất:

$$P(B|A) = \frac{P(A|B)P(B)}{P(A)}$$

- **Ý nghĩa trong Khoa học Dữ liệu:** Chuyển đổi từ câu hỏi khó tính toán $P(\text{kết quả}|\text{dữ liệu})$ thành câu hỏi dễ tính toán hơn nhiều là $P(\text{dữ liệu}|\text{kết quả})$.

4. Biểu diễn Phân phối: PDF và CDF

Hàm mật độ xác suất (PDF):

- Đồ thị biểu diễn xác suất của từng giá trị cụ thể X mà biến ngẫu nhiên có thể nhận.
- Có mối quan hệ mật thiết với biểu đồ tần số (Histogram) thực tế (được chuẩn hóa theo tổng số lượng mẫu).
- Diện tích dưới đường cong của PDF luôn bằng 1.

Hàm phân bố tích lũy (CDF):

- Là tổng tích lũy của PDF, phản ánh xác suất $X \leq k$ thay vì $X = k$.
- Đồ thị luôn tăng đơn điệu từ trái sang phải, đạt giá trị lớn nhất bằng 1 ở cực phải.
- **Tính tương đương:** PDF và CDF chứa thông tin hoàn toàn giống nhau nhưng thể hiện dưới dạng đồ thị khác nhau.

5. Thống kê mô tả: Đo lường xu hướng trung tâm

- **Trung bình cộng (Mean):** $\mu = \frac{1}{N} \sum_{i=1}^N x_i$. Phù hợp cho các phân phối đối xứng và không có giá trị ngoại lệ (như chiều cao, cân nặng).
- **Trung vị (Median):** Giá trị nằm chính giữa tập dữ liệu đã sắp xếp. **Cực kỳ mạnh mẽ (robust)** trước các giá trị ngoại lệ cực đoan (outliers).
- **Trung bình nhân (Geometric Mean):** Căn bậc n của tích n phần tử. Nhạy cảm với các giá trị gần bằng 0 (một giá trị 0 sẽ đưa trung bình nhân về 0). Thích hợp cho việc tính tỷ lệ tăng trưởng.
- **Yếu vị (Mode):** Giá trị xuất hiện nhiều nhất. Trong thực tế đối với dữ liệu thực đo trên phạm vi rộng, Mode ít khi đại diện tốt cho giá trị trung tâm và dễ bị ảnh hưởng bởi lỗi nhập liệu hoặc giá trị mặc định.

6. Đo lường sự biến thiên của phân phối

Độ lệch chuẩn (σ) và Phương sai (V):

- Phương sai $V = \sigma^2$ đo lường mức độ phân tán của dữ liệu xung quanh giá trị trung bình.
- Công thức tính độ lệch chuẩn mẫu:

$$\sigma = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (a_i - \bar{a})^2}$$

- Việc bình phương các hiệu số khiến độ lệch chuẩn cực kỳ nhạy cảm với các giá trị ngoại lệ xa trung bình.

Bất đẳng thức Chebyshev:

- **Bất chấp hình dạng phân phối thô**, ít nhất $(1 - 1/k^2)$ khối lượng dữ liệu phải nằm trong khoảng $\pm k$ độ lệch chuẩn so với giá trị trung bình.
- Ít nhất **75%** dữ liệu nằm trong khoảng $\mu \pm 2\sigma$.
- Ít nhất **89%** dữ liệu nằm trong khoảng $\mu \pm 3\sigma$.
- **Lời khuyên thực hành:** Luôn báo cáo phân phối dưới dạng cặp $\mu \pm \sigma$.

7. Hệ số tương quan: Pearson vs Spearman

Hệ số tương quan Pearson (r):

- Đo lường mức độ phù hợp của một mô hình dự báo tuyến tính $y = mx + b$.
- Sử dụng hiệp phương sai ở tử số và độ lệch chuẩn ở mẫu số.
- Trả về giá trị từ -1 đến 1 . Giá trị 0 biểu thị không có mối quan hệ tuyến tính (mặc dù vẫn có thể có quan hệ phi tuyến tính hoàn hảo).

Hệ số tương quan hạng Spearman (ρ):

- Chuyển đổi dữ liệu gốc thành các thứ hạng (rank) trước khi tính toán.
- Đo lường mức độ quan hệ đơn điệu (monotonic) giữa hai biến số, bất chấp nó có tuyến tính hay không.
- **Đặc tính:** Rất mạnh mẽ trước các giá trị ngoại lệ ở hai đầu phân phối.

8. Tương quan không đồng nghĩa với Nhân quả!

- **Mối quan hệ một chiều:** Trong trường hợp tốt nhất, tương quan chỉ gợi ý mối quan hệ nhân quả một chiều (A gây ra B).
- **Tương quan giả tạo (Spurious Correlation):** Nhiều mối tương quan rất mạnh mẽ trong thực tế hoàn toàn do ngẫu nhiên hoặc do một biến thứ ba điều phối.
- Ví dụ kinh điển: Số lượng bằng Tiến sĩ Khoa học Máy tính trao mỗi năm tương quan chặt chẽ ($r = 0.985$) với doanh thu từ các máy chơi trò chơi điện tử xèng (Arcades).
- **Bài học xương máu:** Chỉ có rất ít công cụ thống kê thuần túy để chứng minh nhân quả trực tiếp. Cách chắc chắn nhất là tiến hành các thí nghiệm có kiểm soát (A/B testing) để chủ động can thiệp vào biến độc lập.

9. Sức mạnh của Logarit trong Khoa học Dữ liệu

Logarit không chỉ là một công cụ thuật toán mà đóng ba vai trò toán học vô cùng quan trọng:

- ➊ **Chuyển tích xác suất thành tổng:** Trong các mô hình độc lập (như Naive Bayes), tích các xác suất nhỏ dễ dẫn đến lỗi tràn số dưới (underflow). Logarit chuyển tích thành tổng:

$$\log(p_1 \cdot p_2) = \log p_1 + \log p_2$$

- ➋ **Biểu diễn tỷ lệ đối xứng:** Tỷ lệ số học thông thường bị bất đối xứng (tỷ lệ $1/2$ ép trong khoảng $[0, 1]$ còn tỷ lệ $2/1$ kéo dài đến vô cực). Phép thế logarit $\log_2(2/1) = 1$ và $\log_2(1/2) = -1$ giúp biến động tăng và giảm đối xứng hoàn hảo qua gốc tọa độ 0.
- ➌ **Chuẩn hóa các phân phối lệch thô:** Áp dụng phép biến đổi logarit cho các biến tuân theo quy luật phân bố lũy thừa (power-law, đuôi dài) để đưa chúng về dạng phân phối hình chuông đối xứng hơn (log-normal), giúp các thuật toán máy học hoạt động ổn định và hiệu quả hơn.

Tổng kết chương 2: Bài học cho Nhà Khoa học Dữ liệu

Thông điệp cốt lõi

- Toán học, xác suất và thống kê là ngôn ngữ chính thức để chúng ta diễn giải, nén dữ liệu và giao tiếp một cách chặt chẽ.
- **Nguyên tắc trung thực:** Luôn báo cáo cả giá trị trung bình lẫn độ lệch chuẩn ($\mu \pm \sigma$) để mô tả đầy đủ bức tranh của phân phối.
- **Sự hoài nghi khoa học:** Tương quan cao chỉ là điểm khởi đầu, tuyệt đối không được tự ý kết luận mối quan hệ nhân quả nếu chưa qua kiểm chứng thí nghiệm có kiểm soát hoặc lập luận định tính sâu sắc.