

CHƯƠNG 3: XỬ LÝ DỮ LIỆU THÔ

The Data Science Design Manual

Trần Văn Long

Trường Đại học Giao thông vận tải

Tháng 9, 2026

1. Tổng quan & Triết lý cốt lõi

Thực tế phũ phàng:

- Hầu hết các nhà khoa học dữ liệu dành phần lớn thời gian cho việc **làm sạch** và **định dạng** dữ liệu (data munging/wrangling).
- Rất ít thời gian thực sự được dành cho việc huấn luyện thuật toán học máy siêu việt.

Mục tiêu của Chương 3:

- Tìm hiểu cơ chế thu thập dữ liệu.
- Kỹ thuật định dạng và chuẩn hóa dữ liệu.
- Nhận diện và sửa chữa các lỗi hệ thống trước khi phân tích.

Châm ngôn lịch sử

"Đã có hai lần tôi được hỏi: 'Thưa ông Babbage, nếu ông nhập sai số liệu vào máy, liệu máy có cho ra kết quả đúng không?'... Tôi không thể hiểu rõ sự nhầm lẫn về ý tưởng nào có thể dẫn đến câu hỏi như vậy."

— Charles Babbage

Nguyên tắc tối thượng

"ĐẦU VÀO RÁC → ĐẦU RA RÁC"
(Garbage In, Garbage Out)

2. Ngôn ngữ dành cho Khoa học dữ liệu

Ngôn ngữ	Đặc trưng cốt lõi	Lĩnh vực áp dụng tối ưu
Python	Dễ học, hỗ trợ lập trình hướng đối tượng tốt, cộng đồng lớn với vô vàn thư viện chuẩn mạnh mẽ.	Sản xuất thương mại (Production), thu thập web (BeautifulSoup, Scrapy).
R	Được thiết kế bởi và dành cho các nhà thống kê, thư viện trực quan hóa xuất sắc.	Phân tích khám phá (Exploratory Data Analysis, EDA), nghiên cứu lý thuyết.
Matlab	Tối ưu hóa tuyệt hảo cho các phép toán ma trận, đại số tuyến tính và thuật toán ML cơ bản.	Kỹ thuật điện, mô phỏng học sâu.
Java / C++	Ngôn ngữ biên dịch hiệu năng cao, quản lý bộ nhớ tốt cho hệ thống khổng lồ.	Dữ liệu lớn phân tán (Hệ thống Hadoop, Apache Spark).

3. Tầm quan trọng của môi trường Notebook

Triết lý phát triển sản phẩm dữ liệu:

- Sản phẩm cuối cùng của dự án khoa học dữ liệu không đơn thuần là một file mã nguồn chạy xong rồi thôi.
- Nó phải là một **Sổ tay tính toán (computable notebook)** tích hợp trọn vẹn mã nguồn, đồ họa trực quan và lập luận bằng văn bản (như Jupyter hay Mathematica).

Tại sao phải dùng Notebook?

- Kết quả tính toán là một chuỗi dài các quyết định thiết kế và lựa chọn tham số phức tạp.
- Không có gì tệ hơn một sản phẩm dữ liệu cuối cùng mà không rõ

3 Trụ cột của tài liệu Notebook

- 1 **Khả năng điều chỉnh (Adjustable):** Khi thay đổi thuật toán hoặc tham số, toàn bộ sổ tay có thể chạy lại tự động để cập nhật kết quả mới.
- 2 **Khả năng tái tạo (Reproducible):** Quy trình đi trực tiếp từ dữ liệu thô đầu vào → dữ liệu sạch đầu ra mà không có bước can thiệp thủ công bằng tay vốn dễ sinh lỗi.
- 3 **Khả năng tự ghi chép (Documented):** Thuyết

4. Các định dạng dữ liệu tiêu chuẩn

Dữ liệu thô cần được lưu trữ ở các định dạng chuẩn hóa để máy tính dễ dàng phân tích và con người dễ dàng đọc được:

- **CSV (Comma Separated Values):**
 - Định dạng đơn giản nhất để trao đổi dữ liệu bảng giữa các chương trình.
 - **Điểm yếu:** Dễ lỗi khi giá trị chứa dấu phẩy (Ví dụ: "Thurston Howell, Jr."). Giải pháp tốt hơn là sử dụng **TSV** (phân tách bằng dấu tab).
- **XML (eXtensible Markup Language):** Dữ liệu có cấu trúc phi bảng, sử dụng các cặp thẻ tag (giống HTML) bao quanh văn bản, hỗ trợ trình phân tích cú pháp chuẩn hóa mạnh mẽ.
- **JSON (JavaScript Object Notation):** Lưu trữ các cặp thuộc tính-giá trị. Là định dạng tối ưu để truyền tải cấu trúc dữ liệu phức tạp phi tuyến tính (mảng lồng nhau, cây thư mục) giữa các hệ thống.
- **Protocol Buffers (Google) / Apache Thrift (Facebook):** Định dạng nhị phân nhẹ hơn XML, tối ưu hóa băng thông để truyền tải dữ liệu dung lượng lớn giữa các máy chủ.
- **Cơ sở dữ liệu SQL (Structured Query Language):** Giải pháp lưu

5. Các phương pháp thu thập dữ liệu

A. Tìm kiếm nguồn sẵn có:

- **Chính phủ:** Kho dữ liệu mở (như Data.gov có hơn 100,000 bộ dữ liệu). Luật tự do thông tin (FOI) cho phép yêu cầu dữ liệu chính thức.
- **Học thuật:** Google Scholar hoặc liên hệ trực tiếp các nhà nghiên cứu để xin tập dữ liệu gốc.
- **Doanh nghiệp:** Qua cổng API có giới hạn tốc độ (rate limit) để bảo vệ hạ tầng.

B. Nhập liệu thủ công (Nhập tay):

C. Quét dữ liệu Web (Scraping & Crawling):

- **Spidering:** Tải danh sách trang tự động.
- **Scraping:** Trích xuất thông tin có cấu trúc từ mã nguồn HTML (thư viện BeautifulSoup).
- **Lưu ý:** Phải tuân thủ điều khoản dịch vụ (TOS) và tôn trọng băng thông máy chủ (tần suất ≤ 1 yêu cầu/giây).

D. Huy động cộng đồng (Crowdsourcing):

- Sử dụng lực lượng lao động từ

6. Làm sạch dữ liệu: Lỗi (Errors) vs. Hiện vật (Artifacts)

Khi tiếp cận một tập dữ liệu mới, việc đầu tiên là phải phát hiện các điểm bất thường thông qua quy trình làm sạch dữ liệu:

Lỗi dữ liệu (Errors)

- Là sự **mất mát thông tin vĩnh viễn** ở mức vật lý trong quá trình thu thập.
- **Ví dụ:** Nhiễu Gaussian làm mờ tín hiệu cảm biến; mất 2 giờ dữ liệu ghi nhật ký do sập nguồn máy chủ.
- **Hệ quả:** Không thể khôi phục, chỉ có thể chấp nhận nhiều.

Hiện vật hệ thống (Artifacts)

- Là các **lỗi mang tính hệ thống** phát sinh từ quá trình xử lý hoặc hợp nhất thông tin thô ban đầu.
- **Ví dụ:** Lỗi gộp trùng lặp tên tác giả; lỗi chia tách cổ phiếu 2-đổi-1 làm sụt giá trị ảo.
- **Hệ quả:** Có thể sửa chữa triệt để nếu chúng ta phát hiện ra và vẫn giữ nguyên bản sao dữ liệu thô gốc.

Phương pháp phát hiện: "Thử nghiệm khứu giác" (Smell Test):

- Quan sát trực quan bằng cách vẽ biểu đồ phân phối tần số

7. Các thách thức về tương thích dữ liệu khi tích hợp

Khi tích hợp dữ liệu từ nhiều nguồn khác nhau, chúng ta sẽ đối mặt với các rào cản nghiêm trọng về sự không tương thích:

- **Chuyển đổi đơn vị đo lường:**
 - Nhầm lẫn đơn vị Anh (Pound/Feet) và hệ mét (Kg/Meter).
 - **Cảnh báo lịch sử:** NASA từng mất tàu quỹ đạo khí hậu sao Hỏa trị giá \$125 triệu vì một nhóm lập trình dùng đơn vị đo Anh, nhóm khác dùng hệ mét.
- **Thông nhất mã ký tự:** Các trang web khác nhau dùng các chuẩn mã hóa khác nhau (ASCII, ISO 8859-1, UTF-8).
- **Thông nhất định danh (Names):** Sự không nhất quán của tên riêng (Ví dụ: "José" vs. "Jose"). Phải chuẩn hóa chuỗi viết thường, loại bỏ ký tự đặc biệt, rút gọn tên đệm.
- **Thông nhất thời gian:** Đồng hồ máy tính không bao giờ khớp nhau hoàn hảo. Hãy quy đổi tất cả dấu thời gian về **Giờ phối hợp quốc tế (UTC)**.
- **Thông nhất tài chính:** Phải thực hiện chuyển đổi tỷ giá hối đoái và đặc biệt là điều chỉnh

8. Xử lý các giá trị bị thiếu & Giá trị ngoại lệ

Giải quyết giá trị bị thiếu (Missing Values)

- **Giải pháp 1: Loại bỏ hoàn toàn bản ghi.**

- Đơn giản, hiệu quả khi lượng dữ liệu cực lớn.
- Nguy hiểm nếu dữ liệu bị thiếu mang tính hệ thống (ví dụ: người giàu thường từ chối khai báo lương).

- **Giải pháp 2: Điền khuyết (Imputation).**

- Điền bằng giá trị trung bình/trung vị của cột.
- Thay thế bằng một giá trị

Phát hiện và sàng lọc giá trị ngoại lệ

- Điểm ngoại lệ có thể là tín hiệu của lỗi thu thập dữ liệu hoặc lỗi nhập liệu (ví dụ: Methuselah sống 969 năm).

- **Phương pháp lọc:**

- Sắp xếp dữ liệu để kiểm tra giá trị nhỏ nhất và lớn nhất của mỗi cột.
- Trực quan hóa bằng biểu đồ tần số hoặc biểu đồ chấm để nhận diện các điểm cực đoan nằm quá xa ranh giới chuẩn.

- **Hành động:** Dừng chỉ đơn giản

9. Câu chuyện chiến trường: Dự án "Đánh bại thị trường"

Bối cảnh dự án Lydia/TextMap:

- Hệ thống Lydia thu thập dữ liệu tin tức khổng lồ hàng ngày, trích xuất tần suất và cảm xúc (tích cực/tiêu cực) đối với hàng triệu thực thể.
- Wenbin (sinh viên cao học của tác giả) đã phát triển mô hình mô phỏng giao dịch chứng khoán dựa trên dữ liệu cảm xúc tích cực của doanh nghiệp trong ngày.

Sự hào hứng ban đầu:

- Wenbin báo cáo rằng mô hình đang mang lại lợi nhuận tuyệt

Hiện thực phũ phàng từ thị trường

Thuyết thị trường hiệu quả:

- Mọi tin tức công khai ngay lập tức được phản ánh vào sự thay đổi giá cổ phiếu của thị trường thực tế.
- Một hệ thống dựa trên quét tin tức web không thể nào phản ứng đủ nhanh (ở mức phần trăm giây) để tận dụng chênh lệch giá trước khi thị trường tự điều chỉnh.

Bài học xương máu

Luôn giữ thái độ hoài nghi lành mạnh

10. Tổng kết chương

3 Thông điệp cốt lõi cần ghi nhớ

- ❶ **Làm sạch dữ liệu là cốt lõi của thành công:** Một mô hình đơn giản chạy trên một tập dữ liệu được chuẩn hóa và làm sạch cẩn thận luôn cho kết quả tốt hơn nhiều so với thuật toán học sâu siêu phức tạp chạy trên một tập dữ liệu thô đầy nhiễu.
- ❷ **Tư duy bảo tồn dữ liệu gốc:** Luôn lưu trữ riêng biệt dữ liệu gốc thô (raw data) và dữ liệu đã làm sạch (cleaned data). Hãy viết code tự động hóa quy trình làm sạch để có thể đảo ngược hoặc điều chỉnh dễ dàng bất cứ lúc nào.
- ❸ **Dừng chỉ tin vào thuật toán:** Hãy thực hiện "kiểm tra khứu giác" thủ công đối với dữ liệu bằng cách vẽ biểu đồ, quan sát trực quan các điểm cực đại/cực tiểu và đặt câu hỏi hoài nghi về ý nghĩa thực tế đằng sau các con số.