

CHƯƠNG 5: PHÂN TÍCH THỐNG KÊ

The Data Science Design Manual

Trần Văn Long

Trường Đại học Giao thông vận tải

Tháng 9, 2026

Suy luận thống kê là gì?

Mối quan hệ hai chiều giữa Xác suất và Thống kê

Nguyên lý hoạt động

- **Lý thuyết Xác suất:** Đi từ quần thể đầy đủ (Population) để suy ra các thuộc tính của mẫu thử nghiệm (Sample).
- **Suy luận Thống kê:** Đi theo chiều ngược lại, cố gắng phán đoán và suy rộng các đặc tính của toàn bộ quần thể dựa trên một mẫu quan sát nhỏ.

Thử nghiệm khứu giác (Smell Test)

- Nhà khoa học dữ liệu giỏi phải học cách hoài nghi dữ liệu thực tế.
- Dữ liệu thực nghiệm thường chứa lỗi, nhiễu và thiên lệch hệ thống.
- Phải tiếp cận đủ gần để phát hiện xem liệu dữ liệu có phải là "rác" hay không.

Các phân phối thống kê cổ điển (Phần 1)

Phân phối Nhị thức và Phân phối Gaussian

Phân phối Nhị thức (Binomial)

- Mô hình hóa số lần thành công x trong n phép thử độc lập với xác suất thành công p .
- Các tham số đặc trưng:
 - Trung bình: $\mu = np$
 - Độ lệch chuẩn:
$$\sigma = \sqrt{np(1-p)}$$
- Có hình dạng đối xứng tiệm cận chuẩn khi n lớn.

Phân phối Chuẩn (Gaussian)

- Phân phối hình chuông đối xứng liên tục hoàn hảo, phổ biến nhất trong tự nhiên (sai số đo lường, chiều cao).
- Xác định hoàn toàn bởi μ và σ .
- **Quy tắc 68–95–99.7:**
 - 68% dữ liệu nằm trong khoảng $\mu \pm 1\sigma$.
 - 95% dữ liệu nằm trong khoảng $\mu \pm 2\sigma$.
 - 99.7% dữ liệu nằm trong khoảng $\mu \pm 3\sigma$.

Các phân phối thống kê cổ điển (Phần 2)

Phân phối Poisson và Quy luật Lũy thừa

Phân phối Poisson

- Đo lường tần suất hoặc khoảng thời gian giữa các sự kiện hiếm gặp xảy ra độc lập.
- Hàm mật độ xác suất dạng đóng:

$$P(X = x) = \frac{e^{-\mu} \mu^x}{x!}$$

- Ứng dụng: Dự báo số lượng cuộc gọi đến tổng đài, số vụ hỏng hóc thiết bị, v.v.

Quy luật lũy thừa (Power Law)

- Biểu diễn sự bất bình đẳng lớn trong xã hội (phân bố tài sản, tần suất từ vựng - Định luật Zipf, số liên kết mạng xã hội).
- Hàm mật độ xác suất:
 $P(X = x) = cx^{-\alpha}$.
- Biểu diễn bằng đường thẳng trên đồ thị log-log.
- **Lưu ý:** Trung bình và độ lệch chuẩn không phản ánh đúng hình dạng thực tế của phân phối này.

Kỹ thuật lấy mẫu từ phân phối xác suất

Inverse Transform Sampling & Monte Carlo Method

- **Lấy mẫu biến đổi nghịch đảo (Inverse Transform Sampling):**

- Phương pháp tổng quát để lấy mẫu từ bất kỳ phân phối một chiều nào có hàm phân phối tích lũy (CDF) $C(x)$.
- Sinh một số ngẫu nhiên đồng nhất $p \in [0, 1]$, sau đó báo cáo giá trị x sao cho $C(x) = p$ (nghịch đảo $x = C^{-1}(p)$).

- **Lấy mẫu Monte Carlo (Thử-Sai ngẫu nhiên):**

- Sử dụng các phép toán số học ngẫu nhiên để mô phỏng thế giới phức tạp.
- Ví dụ: Lấy mẫu đều bên trong hình tròn bằng cách sinh điểm ngẫu nhiên trên hình vuông bao quanh và loại bỏ (reject) các điểm nằm ngoài hình tròn. Tránh sai lầm lấy mẫu theo góc/bán kính trực tiếp gây nén điểm ở tâm.

Ý nghĩa thống kê so với Kích thước hiệu ứng

Phân biệt độ tin cậy và tầm quan trọng thực tế

Ý nghĩa thống kê (Significance)

- Trả lời câu hỏi: *Mối tương quan hay sự khác biệt này có khả năng xảy ra do ngẫu nhiên hay không?*
- Phụ thuộc cực kỳ mạnh vào kích thước mẫu n . Với mẫu đủ lớn, những hiệu ứng cực kỳ nhỏ cũng có ý nghĩa thống kê.
- Đề phòng **Tương quan giả** (Spurious correlation).

Kích thước hiệu ứng (Effect Size)

- Trả lời câu hỏi: *Sự khác biệt hay mức độ ảnh hưởng thực tế là bao nhiêu?*
- **Độc lập với kích thước mẫu n .**
- Các thước đo phổ biến:
 - Hệ số tương quan Pearson r .
 - Hệ số Cohen's d :

$$d = \frac{|\mu_1 - \mu_2|}{\sigma}$$

- Tỷ lệ phần trăm chồng chéo giữa hai phân phối.

Kiểm định T (Student's t-test)

So sánh giá trị trung bình giữa hai quần thể phân phối chuẩn

Mục tiêu & Công thức

Sử dụng kiểm định t Welch cho hai nhóm mẫu có phương sai khác nhau:

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$$

Trong đó $\bar{x}_i, \sigma_i, n_i$ lần lượt là giá trị trung bình, độ lệch chuẩn và kích thước mẫu của nhóm i .

Độ tin cậy của kiểm định tăng khi:

- **Tử số lớn:** Sự khác biệt trung bình giữa hai nhóm rất rõ rệt.
- **Độ lệch chuẩn nhỏ:** Các giá trị quan sát tập trung chặt chẽ quanh trung bình, ít biến động.
- **Cỡ mẫu lớn:** Tăng tính đại diện và giảm sai số lấy mẫu.

Kiểm định Kolmogorov-Smirnov (KS Test)

So sánh hai phân phối mẫu không cần giả định dạng hình chuông

Nguyên lý kiểm định

- So sánh trực tiếp hai hàm phân phối tích lũy (CDF) của hai mẫu dữ liệu.
- Tìm giá trị x mà tại đó khoảng cách dọc giữa hai CDF là lớn nhất.
- Chỉ số thống kê KS được tính bằng:

$$D(C_1, C_2) = \max_{-\infty \leq x \leq \infty} |C_1(x) - C_2(x)|$$

- So sánh $D(C_1, C_2)$ với giá trị tra bảng để đưa ra kết luận bác bỏ

Ưu điểm vượt trội

• Phi tham số

(Non-parametric): Không yêu cầu dữ liệu phải tuân theo phân phối chuẩn như kiểm định t .

- **Trực quan hóa trực tiếp:** Giúp dễ dàng nhận diện vị trí lệch pha lớn nhất giữa hai phân phối (như ở phần thân hay phần đuôi).

- Ít giả định kỹ thuật phức tạp, giảm thiểu lỗi sử dụng sai phép thử.

Kiểm định đa giả thuyết & Cách hiệu chỉnh

Giải quyết bài toán P-hacking khi phân tích dữ liệu lớn đa chiều

- **Vấn đề:** Khi kiểm tra đồng thời hàng ngàn giả thuyết, xác suất xuất hiện các phát hiện giả mạo do ngẫu nhiên đạt mức ý nghĩa $\alpha = 0.05$ là cực kỳ cao.
- **Hiệu chỉnh Bonferroni:**
 - Phương pháp cực kỳ nghiêm ngặt bảo vệ chống lại lỗi Dương tính giả.
 - Hạ thấp ngưỡng ý nghĩa xuống mức: $\alpha' = \frac{\alpha}{m}$ (với m là số lượng giả thuyết/phép thử).
 - *Hạn chế:* Có xu hướng quá khắt khe, dễ bỏ sót các hiệu ứng thực tế (Tăng Âm tính giả).
- **Kiểm soát tỷ lệ phát hiện sai (False Discovery Rate - FDR):**
 - Phương pháp Benjamini–Hochberg sắp xếp các giá trị p theo thứ tự tăng dần.
 - Chấp nhận ý nghĩa của giả thuyết i nếu và chỉ nếu:

$$p_i \leq \frac{i}{m} \alpha$$

- Cân bằng tốt hơn giữa độ chính xác và độ nhạy của phép thử trên dữ liệu lớn

Kiểm định Hoán vị và Suy luận Bayes

Sức mạnh của tính toán hiện đại và triết lý cập nhật niềm tin

Kiểm định Hoán vị (Permutation Test)

- Phương pháp phi tham số mạnh mẽ, tận dụng năng lực tính toán.
- Xáo trộn ngẫu nhiên nhãn của dữ liệu nhiều lần (ví dụ 1,000 hay 1,000,000 lần) để tạo ra phân phối giả thuyết không (H_0).
- Tính toán tỷ lệ số lần kết quả mô phỏng ngẫu nhiên vượt trội hơn kết quả thực tế để tìm giá trị p .

Suy luận Bayes

- Triết lý cập nhật xác suất tiên nghiệm (prior) $P(A)$ dựa trên bằng chứng mới B để thu được xác suất hậu nghiệm (posterior) $P(A|B)$:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

- Phản ánh tư duy khoa học dữ liệu đúng đắn: bắt đầu bằng một giả định ban đầu về thế giới và liên tục hiệu chỉnh nó khi có

Tổng kết chương 5

Thông điệp cốt lõi cho nhà khoa học dữ liệu

- **Sự trung thực trong trình bày dữ liệu:** Luôn báo cáo đồng thời cả giá trị trung bình và độ lệch chuẩn dưới dạng $\mu \pm \sigma$.
- **Hiểu rõ phân phối dữ liệu trước khi hành động:** Tránh giả định mù quáng rằng mọi thứ đều tuân theo phân phối chuẩn. Quy luật lũy thừa và phân phối Poisson xuất hiện ở khắp mọi nơi.
- **Ý nghĩa thống kê chỉ là bước đầu:** Hãy luôn phân tích kích thước hiệu ứng thực tế (Effect Size) để xác định tầm quan trọng thương mại và xã hội thực sự của mô hình.
- **Làm chủ kỹ thuật mô phỏng và kiểm định:** Tận dụng sức mạnh tính toán hiện đại (như kiểm định hoán vị, mô phỏng Monte Carlo) để giải quyết các bài toán thống kê thực tiễn mà không bị ràng buộc bởi các công thức giải tích cổ điển.