

CHƯƠNG 6: TRỰC QUAN HÓA DỮ LIỆU

The Data Science Design Manual

Trần Văn Long

Trường Đại học Giao thông vận tải

Tháng 9, 2026

Triết lý & Vai trò của Trực quan hóa

Câu nói kinh điển của Edward Tufte

"Ở khía cạnh tốt nhất, đồ họa là công cụ hỗ trợ tư duy."

Tại sao phải trực quan hóa dữ liệu?

- **Phát hiện lỗi kỹ thuật:** Các điểm dị biệt (outliers), dữ liệu chưa sạch sẽ lập tức lộ diện khi được vẽ đúng cách.
- **Khám phá dữ liệu (EDA):** Giúp hiểu rõ hình dạng phân phối ban đầu của dữ liệu trước khi đưa vào thuật toán.

Lời khuyên từ thực tiễn

Việc đưa trực tiếp dữ liệu thô chưa qua trực quan hóa vào các thuật toán học máy phức tạp là một sai lầm tiềm ẩn nhiều rủi ro hệ thống.

Sự lừa dối của Thống kê Tóm tắt: Bộ tứ Anscombe

Hiện tượng đặc biệt trong Khoa học Dữ liệu

Bốn tập dữ liệu hai chiều khác nhau hoàn toàn nhưng lại có **các chỉ số thống kê tóm tắt trùng khớp hoàn hảo**:

- Giá trị trung bình của x : 9.0
- Giá trị trung bình của y : 7.5
- Phương sai của x : 10.0 /
Phương sai của y : 3.75
- Hệ số tương quan r : 0.816
- Đường hồi quy tuyến tính:
 $y = 0.5x + 3.0$

Nhưng khi trực quan hóa bằng biểu đồ phân tán:

- **Tập I:** Phân phối tuyến tính chuẩn mực có nhiễu.
- **Tập II:** Mỗi quan hệ hình parabol phi tuyến tính hoàn hảo.
- **Tập III:** Tuyến tính tuyệt đối ngoại trừ 1 điểm ngoại lệ cực đoan.
- **Tập IV:** Tất cả x đều bằng 8 ngoại trừ một điểm ngoại lai

Thẩm mỹ Thiết kế & Tỷ lệ Mục Dữ liệu

Triết lý tối giản của Edward Tufte

Một biểu đồ tốt nên tập trung tối đa mực in vào việc biểu diễn dữ liệu cốt lõi, hạn chế tối đa các yếu tố trang trí thừa thãi.

Công thức tỷ lệ mực dữ liệu (Data-Ink Ratio):

$$\text{Tỷ lệ mực dữ liệu} = \frac{\text{Lượng mực dùng để vẽ dữ liệu}}{\text{Tổng lượng mực dùng vẽ đồ họa}}$$

- Mục tiêu: **Tối đa hóa** tỷ lệ này để làm nổi bật dữ liệu.
- Loại bỏ **"Rác biểu đồ"** (Chartjunk): Hiệu ứng 3D,

4 Bước đơn giản hóa biểu đồ cốt lõi:

- 1 **Giải phóng dữ liệu:** Gỡ bỏ hoặc làm mờ nhẹ các lưới tham chiếu nặng nề.
- 2 **Ngừng che khuất:** Loại bỏ các mảng màu nền vô ích.
- 3 **Bỏ khung bao quanh:** Loại bỏ các đường viền trên và bên phải.
- 4 **Tận dụng mực khuyết:** Sử dụng

Tính trung thực trong Đồ họa & Hệ số Nói dối

Hệ số nói dối (Lie Factor) của Tufte:

$$\text{Hệ số nói dối} = \frac{\text{Mức độ ảnh hưởng trong đồ thị}}{\text{Mức độ ảnh hưởng trong dữ liệu thực tế}}$$

Nếu hệ số này khác biệt xa mức 1.0, biểu đồ đang bóp méo sự thật khách quan.

Các "bẫy" gây hiểu lầm thường gặp:

- **Ẩn gốc tọa độ ($y = 0$):** Đối với biểu đồ cột, việc cắt bớt trục y làm phóng đại sự khác biệt tương đối một cách giả tạo.
- **Trục tọa độ không phù hợp:**

Cảnh báo quan trọng

Trình bày các phép nội suy mà không hiển thị các điểm dữ liệu thực tế sẽ che giấu chất lượng thực của mô hình, tước đi quyền phán đoán của người xem.

Quy tắc vàng: Luôn đánh dấu thang đo và nhãn rõ ràng trên các trục để người xem tự phục dựng dữ liệu thô từ biểu đồ của bạn.

Nguyên tắc sử dụng Màu sắc & Sắc độ

Hai vai trò chính của Màu sắc:

- **Phân loại nhóm**

(Categorical): Sử dụng các màu sắc phân biệt rõ ràng để đánh dấu lớp dữ liệu, cụm hoặc nhóm giới tính.

- **Mã hóa giá trị số**

(Sequential): Sử dụng sự thay đổi độ sáng hoặc độ bão hòa màu để biểu thị đại lượng lớn/nhỏ.

Nguyên lý chọn màu thông minh:

- Ưu tiên các màu có **giá trị gợi nhớ liên kết tự nhiên** (ví dụ: tông thất màu đỏ, môi trường

Sai lầm kinh điển: Bản đồ màu cầu vồng

Bản đồ màu cầu vồng có tính **phi tuyến tính về mặt cảm nhận** của mắt người, gây khó khăn cho việc nhận biết mức độ chênh lệch thực sự của giá trị số.

Lời khuyên từ tác giả: Hệ thống màu sắc là một vấn đề kỹ thuật và phức tạp. Bạn nên sử dụng các thang màu chuẩn đã được thiết kế

Trực quan hóa Dữ liệu Bảng & Biểu đồ Đường

Nghệ thuật trình bày dữ liệu dạng Bảng:

- Bảng đặc biệt hữu ích khi hiển thị **số lượng ít các điểm dữ liệu không đồng nhất** và đòi hỏi độ chính xác tuyệt đối.
- **Cần phải các số có độ chính xác đồng nhất** để hỗ trợ so sánh độ lớn bằng mắt thường một cách tự nhiên.
- Sắp xếp thứ tự các hàng theo quy luật có nghĩa (theo quy mô, ngày tháng) thay vì sắp xếp ngẫu nhiên hoặc theo bảng chữ cái.

Các thực hành tốt nhất cho Biểu đồ Đường:

- Biểu đồ đường được dùng để biểu thị một hàm liên tục $y = f(x)$.
- **Cảnh báo:** Tuyệt đối **không nối các điểm đối với dữ liệu phân loại** (ví dụ: giá trị giữa các bang) vì giữa chúng không có sự liên kết logic.
- Hãy hiển thị các điểm dữ liệu thô nhẹ nhàng ở phía sau đường xu hướng đậm để tăng tính minh bạch của mô hình khớp dữ liệu.

Biểu đồ Phân tán & Thách thức từ Dữ liệu lớn

Hiện tượng "Quả cầu đen chết chóc"

Khi số lượng điểm vẽ lên đến hàng chục ngàn hay hàng triệu, các điểm sẽ đè lên nhau tạo thành một khối mực đen xì, làm mất hoàn toàn cấu trúc dữ liệu.

Giải pháp khắc phục lỗi chồng lấp:

- **Thu nhỏ kích thước chấm:** Sử dụng kích thước chấm cực nhỏ đối với các tập dữ liệu lớn.
- **Giảm độ mờ đục (Opacity):** Tăng độ trong suốt để các

Sử dụng các công cụ thay thế:

- **Bản đồ nhiệt màu (Heatmap):** Chia lưới không gian thành các ô nhỏ và tô màu dựa trên tần suất điểm rơi vào ô đó.
- **Rung rinh điểm (Jittering):** Thêm nhiễu ngẫu nhiên nhỏ vào tọa độ số nguyên để phân tách các điểm bị trùng khít tọa độ.
- **Biểu đồ bong bóng:** Điều chỉnh kích thước và màu sắc để biểu thị các chiều thông tin bổ sung.

Biểu đồ Cột vs. Biểu đồ Tròn: Lựa chọn & So sánh

Biểu đồ Cột (Bar Chart):

- Phù hợp cho việc **so sánh chính xác** giữa các danh mục độc lập.
- Mắt người so sánh chiều dài khi có chung gốc tọa độ rất tốt.
- **Nguyên tắc không thể thương lượng:** Trục y của biểu đồ cột bắt buộc phải bắt đầu từ giá trị 0.

Biểu đồ Cột chồng (Stacked Bar):

- Giúp thể hiện cơ cấu phần trăm thành phần nhưng lại gây khó khăn khi so sánh các phần

Biểu đồ Tròn (Pie Chart):

- Dùng để biểu diễn tỷ lệ phần trăm của tổng thể (không quá 5-7 thành phần).
- **Kỹ thuật dán nhãn trực tiếp:** Viết nhãn thông tin ngay trên lát cắt thay vì sử dụng bảng chú giải màu sắc gây xao nhãng mắt người đọc.
- Nhóm các lát cắt quá nhỏ lại thành một lát duy nhất mang tên "Khác".
- Tránh xa các hiệu ứng xoay hay cắt lớp 3D bóp méo diện tích.

Biểu đồ Tần suất (Histogram) vs. Hàm Phân phối Tích lũy (CDF)

Thách thức của Biểu đồ Tần suất (Histogram):

- Hình dạng của histogram phụ thuộc rất lớn vào **số lượng khoảng chia (bin size)**.
- Số bin quá ít làm phẳng các đặc trưng; số bin quá nhiều khiến biểu đồ thừa thớt, gồ ghề vô nghĩa.
- **PDF Normalization:** Nên chuẩn hóa trục y từ số lượng tần suất tuyệt đối thành tỷ lệ phần trăm (mật độ xác suất) để dễ giải thích.

Giải pháp tối ưu: Hàm CDF

Hàm phân phối tích lũy (CDF) là tích phân của hàm mật độ xác suất (PDF), chứa đựng chính xác cùng một lượng thông tin dữ liệu gốc.

Ưu điểm vượt trội của CDF:

- **Không phụ thuộc tham số:** Không cần phải chọn số lượng bins, cho thấy cái nhìn chân thực không bị biến đổi.
- Phản ánh xuất sắc hành vi ở các phần đuôi phân phối (tails).

Các tác phẩm đồ họa kinh điển lịch sử:

- **Lịch trình tàu của Marey (Paris-Lyon):** Biểu diễn hoàn hảo đồng thời hành trình, thời gian, ga đỗ và tốc độ chạy tàu (thông qua độ dốc của các đường).
- **Bản đồ dịch tả Broad Street của John Snow:** Định vị nguồn nước bị nhiễm bệnh bằng cách vẽ chấm ca tử vong trực tiếp lên bản đồ đường phố.

Thông điệp đúc kết

Sự thành công của một trực quan hóa dữ liệu không nằm ở sự phức tạp của công nghệ đồ họa, mà ở sự rõ ràng, chân thực của câu chuyện dữ liệu muốn truyền tải đến khán giả.

3 Nguyên tắc sống còn:

- ❶ Tối đa hóa tỷ lệ mực dữ liệu.
- ❷ Giữ vững tính toàn vẹn và trung thực đồ họa.
- ❸ Cung cấp nhiều góc nhìn khác nhau trên cùng một tập dữ liệu.