

CHƯƠNG 7: MÔ HÌNH TOÁN HỌC

The Data Science Design Manual

Trần Văn Long

Trường Đại học Giao thông vận tải

Tháng 9, 2026

“Tất cả các mô hình đều sai, nhưng một số mô hình lại hữu ích.”
— George Box

Nguyên tắc Dao cạo Occam (Occam's Razor):

- Khi có hai mô hình cùng đưa ra dự đoán chính xác như nhau, chúng ta nên **ưu tiên chọn mô hình đơn giản hơn**.
- **Về mặt triết học**: Giảm thiểu tối đa số lượng giả định tiên nghiệm.
- **Về mặt thống kê**: Hạn chế số lượng tham số tự do để ngăn ngừa mô hình ghi nhớ nhiều.
- Mô hình đơn giản thường **mạnh mẽ (robust)** và **dễ giải thích** hơn mô hình phức tạp.

Đánh đổi Độ lệch & Phương sai (Bias-Variance Tradeoff)

Sự căng thẳng giữa **độ phức tạp mô hình** và **hiệu suất tổng quát hóa** được mô tả qua:

1. Độ lệch (Bias) → Khớp chưa đủ (Underfit)

- Lỗi từ các giả định không chính xác được đưa vào mô hình (ví dụ: ép dữ liệu phi tuyến tính vào hàm tuyến tính).
- Hoạt động kém trên cả dữ liệu huấn luyện và kiểm thử.

2. Phương sai (Variance) → Quá khớp (Overfit)

- Lỗi phát sinh do mô hình quá nhạy cảm với các biến động ngẫu nhiên trong dữ liệu huấn luyện.
- Khớp cực tốt trên tập huấn luyện nhưng **thất bại thảm hại trên tập dữ liệu kiểm thử độc lập**.

Triết lý Dự báo hiệu quả của Nate Silver

Nate Silver (FiveThirtyEight) nổi tiếng với các dự báo bầu cử chính xác nhờ các nguyên tắc:

- **Suy nghĩ theo hướng xác suất:** Dự báo không nên là một con số đơn lẻ, mà phải là **phân phối xác suất** ($\mu \pm \sigma$). Điều này phản ánh sự khiêm tốn trước bất trắc của thế giới thực.
- **Liên tục cập nhật dự báo (Live Models):** Cập nhật niềm tin cũ (xác suất tiên nghiệm) dựa trên các luồng dữ liệu mới nhận được (phương pháp Bayes).
- **Tìm kiếm sự đồng thuận (Consensus):** Thu thập dữ liệu từ nhiều nguồn khác nhau. Sử dụng các kỹ thuật học máy hướng tới đồng thuận như **Boosting** (kết hợp các bộ học yếu) hoặc **Cây quyết định kết hợp** (bỏ phiếu số đông).

Phân loại mô hình: Tuyến tính & Hộp đen

Tuyến tính vs. Phi tuyến tính

- **Tuyến tính (Linear):** Gán trọng số hệ số cho từng đặc trưng và cộng lại. Ưu điểm: dễ hiểu, ổn định, tránh quá khớp trên tập dữ liệu vừa phải.
- **Phi tuyến tính (Non-linear):** Khớp dữ liệu chặt hơn bằng đa thức, logarit, lũy thừa. Khó tối ưu hóa hệ số hơn.

Hộp đen vs. Mô tả

- **Hộp đen (Black-box):** Các mô hình phức tạp (như Deep Learning) đạt hiệu suất rất cao nhưng hoàn toàn không minh bạch về lý do đưa ra quyết định.
- **Mô tả (Descriptive):** Các mô hình như Hồi quy tuyến tính (hệ số lớn nhất ứng với đặc trưng mạnh nhất) hoặc Cây quyết định (truy vết rõ ràng nhánh rẽ).

Phân loại mô hình: Thuyết cơ bản & Ngẫu nhiên

Nguyên lý cơ bản vs. Dựa trên dữ liệu

- **Nguyên lý cơ bản (First-principles):** Dựa trên niềm tin lý thuyết vững chắc về cơ chế vận hành của hệ thống (như định luật Newton).
- **Dựa trên dữ liệu (Data-driven):** Dựa trên các mối tương quan thực nghiệm quan sát được. Dễ dàng huấn luyện lại và thích ứng khi điều kiện thay đổi.

Ngẫu nhiên vs. Xác định & Cấu trúc

- **Ngẫu nhiên (Stochastic):** Tích hợp các khái niệm xác suất (như hồi quy logistic). Tuân thủ các tiên đề xác suất (tổng bằng 1 nhờ hàm phân vùng).
- **Xác định (Deterministic):** Luôn trả về cùng một kết quả với cùng một đầu vào (rất tốt cho việc gỡ lỗi / kiểm thử hồi quy).
- **Phẳng (Flat) vs. Phân cấp (Hierarchical):** Phân tách bài toán lớn thành các bài toán

Tầm quan trọng của Mô hình Cơ sở (Baselines)

Nguyên tắc: Chỉ khi mô hình phức tạp vượt trội hơn mô hình cơ sở đơn giản một cách có ý nghĩa, nó mới thực sự có giá trị.

1. Cho bài toán Phân loại (Classification)

- **Đoán ngẫu nhiên (Random):** Đoán đồng đều hoặc theo phân phối nhân huấn luyện.
- **Nhãn phổ biến nhất:** Nguyên lý “mặt trời sẽ mọc vào ngày mai” (dự đoán lớp đa số).
- **Mô hình đơn đặc trưng tốt nhất:** Tìm đặc trưng đơn lẻ có khả năng phân tách cao nhất, quét qua mọi ngưỡng t để lấy độ chính xác tối ưu.

2. Cho bài toán Dự đoán giá trị (Regression)

- **Giá trị trung bình/trung vị:** Bỏ qua tất cả đặc trưng, luôn đoán giá trị trung tâm của mục tiêu.
- **Giá trị của bước trước đó:** Trong chuỗi thời gian, dự đoán giá trị tương lai bằng giá trị hiện tại (“thời tiết ngày mai giống hôm nay”).

Đánh giá Bộ phân loại & Ma trận nhầm lẫn

Vệ sinh tư duy:

- **Smell Test (Kiểm tra khứu giác):** Xem xét kỹ một vài mẫu dự đoán đúng và sai để hiểu cơ chế hoạt động thực tế.
- **Dương tính giả (FP - Lỗi loại I):** Nhầm lẫn tuyên bố âm tính là dương tính.
- **Âm tính giả (FN - Lỗi loại II):** Nhầm lẫn tuyên bố dương tính là âm tính.

Các chỉ số đánh giá cốt lõi:

- **Độ chính xác (Accuracy)**
$$= \frac{TP+TN}{TP+TN+FP+FN}$$
: Gây hiểu lầm lớn khi các lớp mất cân bằng cực độ (v.d. phát hiện ung thư hiếm 5%).
- **Độ súc tích (Precision)**
$$= \frac{TP}{TP+FP}$$
: Tỷ lệ dương tính thật trong số được dự đoán dương tính (giảm FP).
- **Độ thu hồi / Độ nhạy (Recall)**
$$= \frac{TP}{TP+FN}$$
: Tỷ lệ phát hiện được các mẫu dương tính thực tế (giảm FN).

- **Điểm F-score**
$$= 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

Đánh giá mô hình Hồi quy & Vệ sinh dữ liệu

Chỉ số lỗi trong hồi quy (Dự đoán số):

- **MSE** (Sai số bình phương trung bình): Phạt cực kỳ nặng các điểm ngoại lệ (outliers) do phép bình phương.
- **RMSE** (Căn MSE): Đưa lỗi về cùng thang đo đơn vị với biến mục tiêu gốc.
- **MAE** (Sai số tuyệt đối trung bình) & **Median Absolute Error**: Thống kê trung vị giúp phản ánh trung thực hơn khi dữ liệu nhiều nhiễu.

Nguyên tắc Vệ sinh dữ liệu (Data Hygiene):

Tách biệt cứng ba tập dữ liệu:

- 1 **Huấn luyện (60%)**: Nghiên cứu và thiết lập tham số.
- 2 **Thử nghiệm (20%)**: Đánh giá so sánh các mô hình khác nhau.
- 3 **Đánh giá (20%)**: **Giữ bí mật tuyệt đối** cho đến phút cuối cùng trước khi đưa vào sản xuất để bảo đảm tính khách quan.

Cảnh báo: Tránh trộn ngẫu nhiên dữ liệu chuỗi thời gian (như giá cổ

Kỹ thuật tối ưu hóa cho Tập dữ liệu nhỏ

Khi dữ liệu quá khan hiếm (ví dụ: dữ liệu y tế lâm sàng hoặc các đời Tổng thống), việc phân tách cứng 3 tập dữ liệu trở nên bất khả thi. Các giải pháp thay thế bao gồm:

- **Kiểm định chéo k-fold (k-fold Cross-validation):**

- Chia dữ liệu thành k phần bằng nhau. Huấn luyện trên $k - 1$ phần và đánh giá trên phần còn lại. Lặp lại k lần.
- **Ưu điểm vượt trội:** Cung cấp cả **giá trị trung bình** và **độ lệch chuẩn** của hiệu suất, giúp lượng hóa độ tin cậy của mô hình.

- **Kiểm định chéo loại trừ một (Leave-one-out):** Trường hợp cực đoan khi $k = n$. Tối đa hóa lượng dữ liệu huấn luyện.

- **Tạo dữ liệu tổng hợp bằng cách làm nhiễu (Noise Injection):**
Nhân bản các mẫu thực tế và thêm một lượng nhiễu ngẫu nhiên nhỏ (phù hợp với sự biến động thực tế) để tăng quy mô dữ liệu và giảm quá khớp.

Mô hình mô phỏng & Tổng kết chương

“Những gì tôi không thể tạo ra, tôi không hiểu.”

— Richard Feynman

Sức mạnh của Mô phỏng (Simulation)

- **Mô phỏng Monte Carlo:** Sử dụng các phép thử ngẫu nhiên lặp lại hàng triệu lần để xây dựng phân phối xác suất kết quả thực tế.
- **Ví dụ Jai-alai:** Mô phỏng 1 triệu trận đấu để phát hiện lỗi thiên lệch vị trí cực kỳ lớn (vị trí 1 và 2 thắng nhiều hơn hẳn) giúp chiến thắng nhà cái.

Thông điệp cốt lõi của Chương 7

- Luôn bắt đầu bằng mô hình cơ sở đơn giản.
- Hiểu rõ ranh giới của sự quá khớp và đánh đổi bias-variance.
- Nghiêm túc tuân thủ vệ sinh dữ liệu huấn luyện/kiểm thử.
- Trực quan hóa lỗi để liên tục tinh chỉnh đặc trưng.