

CHƯƠNG 9: TUYỂN TÍNH VÀ LOGISTIC HỒI QUY

Cẩm nang Thiết kế Khoa học Dữ liệu

Trần Văn Long

Trường Đại học Giao thông vận tải

Tháng 9, 2026

Tổng quan & Bản chất của Hồi quy Tuyến tính

- **Mô hình học máy nền tảng:** Hồi quy tuyến tính là phương pháp tiếp cận cốt lõi nhất để xây dựng các mô hình dự đoán giá trị liên tục từ dữ liệu huấn luyện.
- **Đặc tính vượt trội:** Mô hình cực kỳ dễ xây dựng, trực quan, dễ giải thích các hệ số và hoạt động rất hiệu quả trong các ứng dụng thực tế.
- **Tính đối ngẫu (Dual Transformation):**
 - Phục vụ **đơn giản hóa và nén dữ liệu**: Thay thế một đám mây điểm nhiễu trong mặt phẳng bằng một đường thẳng xu hướng rõ nét.
 - **Ánh xạ toán học**: Mỗi điểm (s, t) ở không gian gốc ánh xạ thành một đường thẳng $y = sx - t$ ở không gian đối ngẫu.
 - Các điểm thẳng hàng ở không gian gốc sẽ đồng quy tại một điểm duy nhất ở không gian đối ngẫu.

Công thức Toán học & Nghiệm Dạng đóng

- **Thiết lập mô hình tuyến tính:**

$$f(x) = w_0 + \sum_{i=1}^{m-1} w_i x_i$$

- **Dạng biểu diễn ma trận:** $Aw = b$

- A : Ma trận dữ liệu kích thước $n \times m$, với cột đầu tiên chứa toàn số 1 để đại diện cho hệ số chặn (intercept) w_0 .
- b : Vectơ chứa các giá trị mục tiêu (target) kích thước $n \times 1$.
- $r = b - Aw$: Vectơ chứa các giá trị phần dư (residuals).

- **Nghiệm bình phương tối thiểu (Least Squares):** Tối thiểu hóa tổng bình phương sai số $J(w) = \|Aw - b\|^2$. Nghiệm dạng đóng tối ưu được tính bằng công thức:

$$w = (A^T A)^{-1} A^T b$$

- **Trường hợp đơn biến:** Đường thẳng tối ưu luôn đi qua trọng tâm $(\bar{x}, \bar{y})$ với độ dốc $w_1 = r_{xy} \frac{\sigma_y}{\sigma_x}$.

Kỹ thuật Nâng cao Chất lượng Mô hình

1. Loại bỏ giá trị ngoại lệ (Outliers)

- Do phạt lỗi theo bình phương phần dư $(y_i - f(x_i))^2$, các điểm ngoại lai có **lực đòn bẩy khổng lồ** làm lệch đường hồi quy.
- Một điểm sai lệch 10 đơn vị có tác động bằng 100 điểm sai lệch 1 đơn vị.
- Giải pháp: Xác định các điểm có phần dư lớn nhất, kiểm tra nguồn gốc và loại bỏ một cách có nguyên tắc để tăng độ khít của mô hình.

2. Khớp hàm phi tuyến (Non-linear)

- Thế giới thực tế là phi tuyến tính. Hồi quy tuyến tính vẫn có thể khớp các đường cong bằng cách mở rộng ma trận đặc trưng A .
- Thêm vào các cột biến đổi phi tuyến tính từ đặc trưng gốc như: $\sqrt{x}$, $\log(x)$, $\frac{1}{x}$, x^2 .
- Thêm đặc trưng tương tác (interaction terms) như x_1x_2 để nắm bắt mối quan hệ nhân tính giữa các biến.

Chuẩn hóa Biến & Vấn đề Đa cộng tuyến

- **Chuẩn hóa đặc trưng (Z-score Scaling):**

- Đưa các đặc trưng về cùng một thang đo bằng phép biến đổi:
$$Z = \frac{x - \mu}{\sigma}.$$
- Giúp các thuật toán tối ưu hóa chạy nhanh và ổn định hơn về mặt số học.
- **Khả năng giải thích:** Sau khi chuẩn hóa, độ lớn của hệ số w_i phản ánh trực tiếp tầm quan trọng tương đối của đặc trưng đó trong mô hình.

- **Biến đổi target phân phối lệch đuôi dài (Power Law):**

- Đối với các biến số phân bố lệch cực đoan (như thu nhập), cần thay thế đặc trưng bằng $\log(x)$ hoặc $\sqrt{x}$ để tránh việc các giá trị cực đại lấn át mô hình.

- **Đa cộng tuyến (Collinearity):**

- Xuất hiện khi các đặc trưng đầu vào tương quan mạnh với nhau, gây mơ hồ và bất ổn số học cho ma trận nghịch đảo $(A^T A)^{-1}$.
- Giải pháp: Tính ma trận hiệp phương sai để phát hiện, loại bỏ bớt biến trùng lặp hoặc sử dụng SVD/PCA để khử tương quan.

Case Study: Tiền boa Taxi & Dao cạo Occam

- **Thiết lập bài toán:** Huấn luyện mô hình hồi quy tuyến tính trên 80 triệu bản ghi chuyến đi taxi tại NYC để dự đoán số tiền boa khách để lại khi trả bằng thẻ tín dụng.
- **So sánh hai mô hình:**
 - **Mô hình 10 biến số** (gồm quãng đường, thời gian, phụ phí, giờ cao điểm, đêm muộn...): Đạt sai số bình phương trung bình **MSE = 1.5448**.
 - **Mô hình đơn biến** (chỉ sử dụng duy nhất biến giá vé hiển thị trên đồng hồ): Đạt sai số **MSE = 1.5487**.
- **Bài học từ Dao cạo Occam (Occam's Razor):**
 - Sự cải thiện cực kỳ nhỏ của mô hình 10 biến thực chất chỉ là nhiễu số học. Mô hình đơn biến thực tế hơn, dễ vận hành và giải thích hơn nhiều.
 - *Lời giải thích đơn giản nhất luôn là tốt nhất.* Luôn xây dựng và đánh giá các mô hình cơ sở (baseline) đơn giản trước khi đầu tư vào học máy phức tạp.

Tối ưu hóa Mô hình bằng Gradient Descent

Không gian tham số lồi

- Hàm mất mát $J(w)$ của hồi quy tuyến tính là một hàm lồi (convex) dạng hình phễu mượt mà.
- **Ưu điểm tuyệt đối:** Chỉ tồn tại duy nhất một cực tiểu địa phương, và nó cũng chính là cực tiểu toàn cục tối ưu nhất.
- Bất kể bắt đầu từ điểm nào, chỉ cần liên tục di chuyển theo hướng đi xuống sẽ luôn chạm tới đáy tối ưu toàn cục.

Thuật toán Giảm độ dốc (Gradient Descent)

- Cập nhật lặp các trọng số w ngược hướng với gradient của hàm mất mát:

$$w_j := w_j - \alpha \frac{\partial J(w)}{\partial w_j}$$

- **Tốc độ học α (Learning Rate):**
 - α quá nhỏ: Hội tụ cực kỳ chậm chạp.
 - α quá lớn: Vượt quá đáy (overshoot) và có thể gây phân kỳ không thể hội tụ.

Stochastic Gradient Descent (SGD) cho Dữ liệu lớn

- **Hạn chế của Gradient Descent truyền thống (Batch GD):**

- Để thực hiện một bước cập nhật duy nhất, thuật toán phải lặp và tính đạo hàm tích lũy trên toàn bộ N mẫu huấn luyện ($O(N)$).
- Với tập dữ liệu lớn như 80 triệu bản ghi taxi NYC, việc tính toán Batch GD trên từng vòng lặp là cực kỳ chậm chạp và bất khả thi về tài nguyên máy tính.

- **Sức mạnh của Stochastic Gradient Descent (SGD):**

- Thay vì tính toán toàn bộ, SGD ước lượng gradient chỉ dựa trên **một mẫu đơn lẻ** (hoặc một mini-batch nhỏ) được chọn ngẫu nhiên tại mỗi bước.
- Cập nhật trọng số liên tục sau mỗi mẫu dữ liệu đi qua.
- Đạt tốc độ hội tụ nhanh hơn gấp nhiều lần, là chìa khóa để giải quyết các bài toán dữ liệu lớn quy mô khổng lồ.

Đơn giản hóa Mô hình qua Regularization

- **Triết lý Regularization:** Thêm thành phần phạt (penalty term) vào hàm mất mát để hạn chế mô hình sử dụng các hệ số có độ lớn cực đoan, chống Overfitting.
- **Hồi quy Ridge (L2 Regularization):**

$$J_{Ridge}(w) = J(w) + \lambda \sum_{j=1}^{m-1} w_j^2$$

- Tránh trường hợp các hệ số triệt tiêu lẫn nhau với giá trị cực lớn (w_1 cực dương lớn, w_2 cực âm lớn). Giữ cho các hệ số nhỏ và phân bố đều.
- **Hồi quy LASSO (L1 Regularization):**

$$J_{LASSO}(w) = J(w) + t \sum_{j=1}^{m-1} |w_j|$$

- Đẩy các hệ số không quan trọng về **chính xác bằng 0**. Đóng vai trò như một bộ tự động lựa chọn đặc trưng (feature selection), tăng tính

Hồi quy Logistic cho bài toán Phân loại

- **Nguyên lý phân loại nhị phân (Binary):** Gán lớp tích cực bằng 1, lớp tiêu cực bằng 0. Thay vì dự đoán một giá trị không giới hạn, hồi quy logistic dự đoán xác suất mẫu thuộc về lớp 1.
- **Hàm Sigmoid / Logit:** Ánh xạ điểm số tuyến tính $h(x, w) = w^T x$ từ khoảng $[-\infty, \infty]$ sang xác suất thuộc khoảng $[0, 1]$:

$$f(x) = \frac{1}{1 + e^{-h(x, w)}}$$

- **Đặc điểm ranh giới:** $f(0) = 0.5$ (ranh giới quyết định mờ). Càng xa ranh giới, độ tin cậy càng tiệm cận về 0 hoặc 1.
- **Hàm mất mát Entropy chéo (Convex Loss Function):**

$$J(w) = -\frac{1}{n} \sum_{i=1}^n [y_i \log(f(x_i)) + (1 - y_i) \log(1 - f(x_i))]$$

- Hàm mất mát này là hàm lồi, đảm bảo tối ưu hóa bằng Gradient Descent luôn đạt nghiệm tốt nhất.

Thách thức & Mở rộng trong Hồi quy Logistic

- **Vấn đề mất cân bằng lớp (Class Imbalance):**

- Khi một lớp quá hiếm (ví dụ: phát hiện gian lận), mô hình xu hướng phân loại tất cả vào lớp đa số để giảm lỗi tổng thể.
- **Giải pháp:** 1) Giảm mẫu (downsampling) lớp đa số, 2) Tăng mẫu (upsampling) lớp thiểu số kèm nhiễu ngẫu nhiên, hoặc 3) Gán trọng số phạt lỗi lớn hơn cho lớp hiếm trong hàm mất mát.

- **Phân loại đa lớp (Multi-class Classification):**

- **Một-với-Tất cả (One-vs-Rest):** Huấn luyện c bộ phân loại nhị phân riêng biệt (lớp i đối đầu phần còn lại). Trả về nhãn có xác suất cao nhất.
- **Cấu trúc phân cấp (Hierarchical Tree):** Nhóm các lớp thành cấu trúc cây quyết định phân cấp giúp cải thiện hiệu năng tính toán theo hàm logarit $\mathcal{O}(\log c)$.
- **Hàm Softmax (Hồi quy đa thức):** Chuẩn hóa điểm số của các lớp để thu được tổng xác suất phân phối bằng đúng 1.