

CHƯƠNG 10: KHOẢNG CÁCH VÀ MẠNG NEURON

Cẩm nang Thiết kế Khoa học Dữ liệu

Trần Văn Long

Trường Đại học Giao thông vận tải

Tháng 9, 2026

Nội dung chính

- 1 Đo khoảng cách
- 2 Phân loại lân cận gần nhất
- 3 Đồ thị, mạng lưới và phân cụm

10.1 Đo khoảng cách & Các chỉ số

- **Ý nghĩa:** Ma trận dữ liệu $n \times d$ định nghĩa tập hợp điểm trong không gian d chiều[cite: 1].
- **Metric khoảng cách:** Hàm khoảng cách $d(x, y)$ là một metric nếu thỏa mãn 4 tính chất[cite: 1]:
 - 1 Tính dương: $d(x, y) \geq 0$ [cite: 1].
 - 2 Đồng thức: $d(x, y) = 0$ khi và chỉ khi $x = y$ [cite: 1].
 - 3 Tính đối xứng: $d(x, y) = d(y, x)$ [cite: 1].
 - 4 Bất đẳng thức tam giác: $d(x, y) \leq d(x, z) + d(z, y)$ [cite: 1].
- **Lưu ý:** Hệ số tương quan hay độ tương đồng cosin không phải là metric chuẩn[cite: 1].

Chỉ số khoảng cách L_k (Minkowski)

- Công thức tổng quát[cite: 1]:

$$d_k(p, q) = \left(\sum_{i=1}^d |p_i - q_i|^k \right)^{1/k}$$

- **Các trường hợp đặc biệt:**

- $k = 1$ (Khoảng cách Manhattan): Tổng độ lệch các chiều, tạo vùng "vòng tròn" hình thoi[cite: 1].
 - $k = 2$ (Khoảng cách Euclidean): Phổ biến nhất, tuân theo định lý Pythagore[cite: 1].
 - $k = \infty$ (Thành phần cực đại): Chỉ xét sai lệch lớn nhất ở một chiều[cite: 1].
- **Bài học:** Chọn k phù hợp ảnh hưởng lớn đến ý nghĩa hàm khoảng cách trong không gian đa chiều[cite: 1].

Chuẩn hóa dữ liệu trong không gian đa chiều

- **Vấn đề trọng số chiều:** Các thước đo L_k ngầm định coi mọi chiều có trọng số như nhau[cite: 1].
- **Sai lầm phổ biến:** Không chuẩn hóa đơn vị đo lường (ví dụ: mét và kilomet) dẫn đến sai lệch hàng triệu lần ở bình phương khoảng cách[cite: 1].
- **Giải pháp chuẩn hóa Z-score[cite: 1]:**

$$z = \frac{x - \mu}{\sigma}$$

- **Bài học cốt lõi:** Thay thế giá trị gốc bằng điểm Z trước khi tính toán khoảng cách để đảm bảo mọi chiều đóng góp công bằng[cite: 1].

10.2 Phân loại lân cận gần nhất (k -NN)

- **Nguyên lý:** Sử dụng các điểm lân cận đã được gán nhãn gần nhất với điểm truy vấn q để dự đoán nhãn hoặc giá trị (hồi quy)[cite: 1].
- **Ưu điểm lớn[cite: 1]:**
 - **Tính đơn giản:** Không có phép toán phức tạp ngoài khoảng cách[cite: 1].
 - **Khả năng giải thích:** Dễ dàng truy nguyên lý do phân loại qua các điểm lân cận[cite: 1].
 - **Tính phi tuyến tính:** Ranh giới quyết định linh hoạt, uốn lượn theo dữ liệu huấn luyện[cite: 1].
- **Cấu trúc hỗ trợ tìm kiếm nhanh:** Sơ đồ Voronoi, Chỉ mục lưới (Grid index), Cây k -d và Băm nhảy cảm vị trí (LSH)[cite: 1].

10.3 & 10.4 Mạng lưới và PageRank

- **Mạng lưới cảm ứng:** Xây dựng đồ thị từ tập điểm dựa trên khoảng cách hoặc thuộc tính chung[cite: 1].
- **Thuộc tính đồ thị:** Có hướng/vô hướng, có trọng số/không trọng số, thưa/dày[cite: 1].
- **PageRank:**
 - Thuật toán cốt lõi của Google, đánh giá tầm quan trọng của đỉnh dựa trên cấu trúc siêu liên kết[cite: 1].
 - Dựa trên mô hình xác suất bước đi ngẫu nhiên và liên quan trực tiếp đến vector riêng của ma trận chuyển đổi[cite: 1].

10.5 Thuật toán phân cụm (Clustering)

- **Mục đích:** Nhóm các điểm dựa trên độ tương đồng để phát hiện giả thuyết, giảm thiểu dữ liệu hoặc phát hiện ngoại lệ[cite: 1].
- **k-means:**
 - Phân chia dữ liệu thành k cụm dựa trên tâm (centroid) hoặc điểm trung tâm (medoid)[cite: 1].
 - Lặp lại qua 2 bước: gán điểm vào tâm gần nhất (Bước E) và cập nhật lại trọng tâm cụm (Bước M)[cite: 1].
 - Xác định k tối ưu bằng phương pháp "khuỷu tay" (elbow method) trên đường cong lỗi MSE[cite: 1].
- **Phân cụm kết hợp (Agglomerative):** Phương pháp từ dưới lên (bottom-up), xây dựng cây phân cấp (dendrogram) dựa trên các liên kết (đơn, trung bình, xa nhất)[cite: 1].

Xin cảm ơn!