

CHƯƠNG 12: DỮ LIỆU LỚN

Cẩm nang Thiết kế Khoa học Dữ liệu

Trần Văn Long

Trường Đại học Giao thông vận tải

Tháng 9, 2026

Nội dung chi tiết chương 12

1. Định nghĩa và Bản chất của Big Data
2. Hạ tầng & Hệ thống lưu trữ phân tán
3. Thuật toán dòng dữ liệu (Streaming Algorithms)
4. Lọc & Lấy mẫu dữ liệu quy mô lớn
5. Tính toán song song & MapReduce
6. Đạo đức dữ liệu & Hệ quả xã hội

Big Data là gì? Thách thức quy mô thực tế

- **Định nghĩa chuẩn:** Dữ liệu lớn không chỉ đơn thuần là tập hợp các tập dữ liệu khổng lồ mà là các bài toán vượt quá khả năng lưu trữ, xử lý, hoặc phân tích của một máy tính đơn lẻ bằng các kỹ thuật truyền thống.
- **Mô hình đa chiều (The 4 Vs):**
 - **Volume (Khối lượng):** Quy mô từ Terabyte đến Petabyte, đòi hỏi kiến trúc phân tán.
 - **Velocity (Tốc độ):** Dòng dữ liệu thời gian thực (streaming data) sinh ra liên tục.
 - **Variety (Sự đa dạng):** Cấu trúc hỗn hợp (có cấu trúc, bán cấu trúc, phi cấu trúc).
 - **Veracity (Độ tin cậy):** Dữ liệu lớn đi kèm với nhiễu lớn (Big Noise).
- **Bản chất kỹ thuật:** Thách thức lớn nhất không phải là chứa dữ liệu mà là trích xuất tin hiệu hữu ích từ hàng đồng nhiễu ngẫu nhiên.

Hệ thống phân cấp lưu trữ và Tính sẵn sàng cao

Phân cấp lưu trữ (Storage Hierarchy):

- **RAM (Bộ nhớ chính):** Truy xuất nhanh nhất nhưng dung lượng hạn chế, chi phí cao.
- **SSD/HDD:** Lưu trữ khối lượng lớn, chi phí thấp hơn nhưng nghẽn cổ chai I/O ngẫu nhiên.
- **Hệ thống tệp phân tán (DFS):** Chia nhỏ tệp thành các khối (blocks) và phân phối trên hàng trăm node.

Đảm bảo độ tin cậy phần cứng:

- **Mô hình sao chép (Replication):** Lưu trữ 3 bản sao trên các rack khác nhau để đề phòng lỗi đĩa cứng.
- **Tính chịu lỗi (Fault Tolerance):** Tự động phát hiện node chết và tái định tuyến tác vụ tính toán sang node khỏe mạnh.

Giới hạn tính toán $O(n)$ và Thuật toán một lần duyệt

- Khi dữ liệu đạt quy mô petabyte, các thuật toán có độ phức tạp thời gian $O(n \log n)$ hoặc quét dữ liệu nhiều lần (multi-pass) trở nên bất khả thi.
- **Yêu cầu của thuật toán Streaming:**
 - Chỉ được phép duyệt qua dòng dữ liệu **đúng một lần duy nhất** (one-pass).
 - Bộ nhớ sử dụng phải cực kỳ nhỏ ($O(1)$ hoặc $O(\log n)$), không phụ thuộc tuyến tính vào kích thước dòng dữ liệu n .
- **Kỹ thuật Băm tiên tiến:** Công cụ cốt lõi để phân phối tải, kiểm tra sự tồn tại (Bloom filters) và ước lượng tần suất (Count-Min Sketch).

Chiến lược Lọc, Lấy mẫu và Bloom Filters

- **Lý do phải lấy mẫu (Sampling):** Không thể huấn luyện mô hình phức tạp trên toàn bộ tập dữ liệu petabyte trong thời gian thực.
- **Lấy mẫu ngẫu nhiên (Random Sampling):** Đảm bảo tính đại diện cho tổng thể, nhưng cần cẩn trọng với các sự kiện hiếm (rare events).
- **Bloom Filters:**
 - Cấu trúc dữ liệu xác suất kiểm tra phần tử thuộc tập hợp với dung lượng bộ nhớ siêu nhỏ.
 - Cho phép xuất hiện *false positive* (báo có nhầm), nhưng tuyệt đối không có *false negative*.

Mô hình Lập trình MapReduce

- **Triết lý cốt lõi:** “Đưa tính toán đến gần dữ liệu” (Compute to Data) để tiết kiệm băng thông mạng.
- **Hai hàm tính toán chính:**
 - **Map(k_1 , v_1) $\rightarrow$ list(k_2 , v_2):** Xử lý song song độc lập trên từng khối dữ liệu, sinh ra các cặp khóa-giá trị trung gian.
 - **Reduce(k_2 , list(v_2)) $\rightarrow$ list(k_3 , v_3):** Gom nhóm tất cả giá trị theo cùng một khóa để tổng hợp kết quả cuối cùng.
- **Giai đoạn Shuffle & Sort:** Cơ chế tự động sắp xếp và truyền tải dữ liệu từ các hàm Map sang các hàm Reduce tương ứng qua mạng.

Đạo đức, Quyền riêng tư và Thiên vị thuật toán

- **Quyền riêng tư (Privacy):** Dữ liệu lớn cho phép tổng hợp thông tin cá nhân chi tiết, rủi ro lộ lọt danh tính ngay cả khi đã ẩn danh (anonymization).
- **Thiên vị thuật toán (Algorithmic Bias):** Dữ liệu lịch sử chứa thành kiến xã hội sẽ khiến mô hình học và củng cố thêm các thành kiến đó trong tài chính, tuyển dụng, tư pháp.
- **Trách nhiệm của Nhà khoa học dữ liệu:** Đảm bảo sự minh bạch, công bằng và tuân thủ các chuẩn mực đạo đức nghiêm ngặt.

Thông điệp cốt lõi

Xử lý Big Data đòi hỏi sự thay đổi toàn diện từ **kiến trúc phần cứng phân tán, tư duy thuật toán một lần duyệt** cho đến **trách nhiệm đạo đức xã hội**.

Thảo luận & Hỏi đáp (Q& A)